Clase 04 - Notas

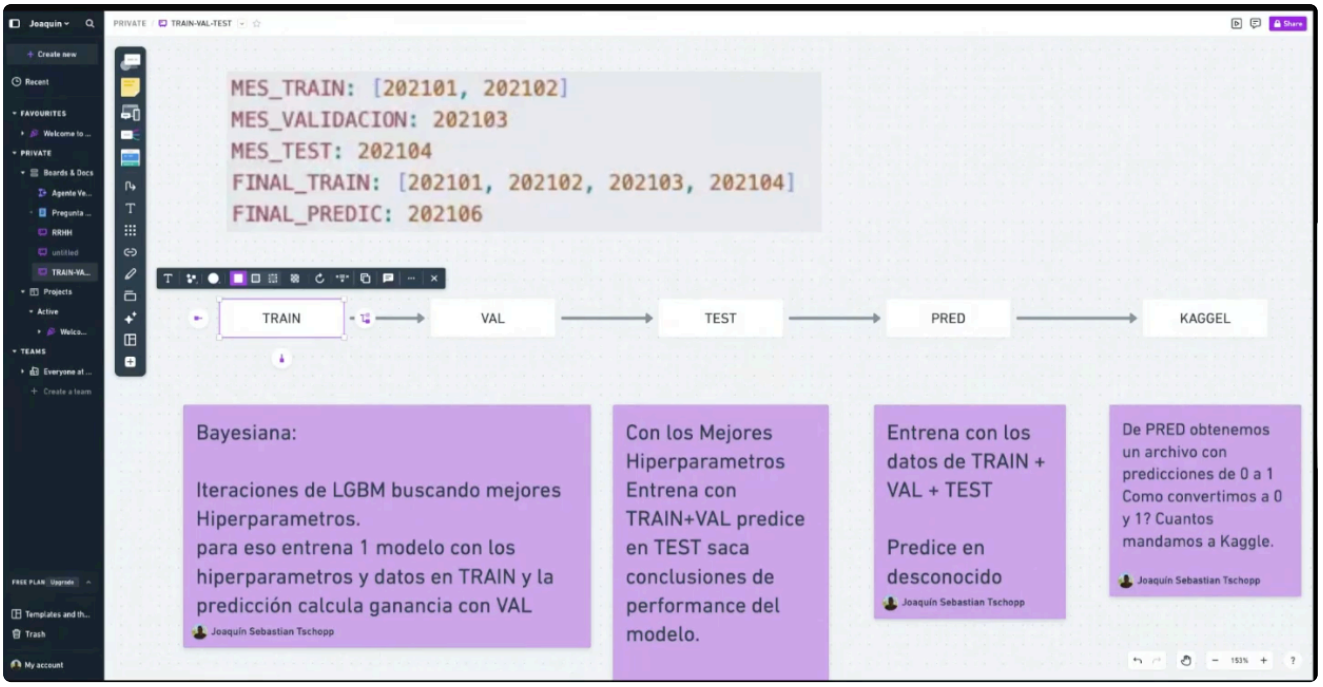

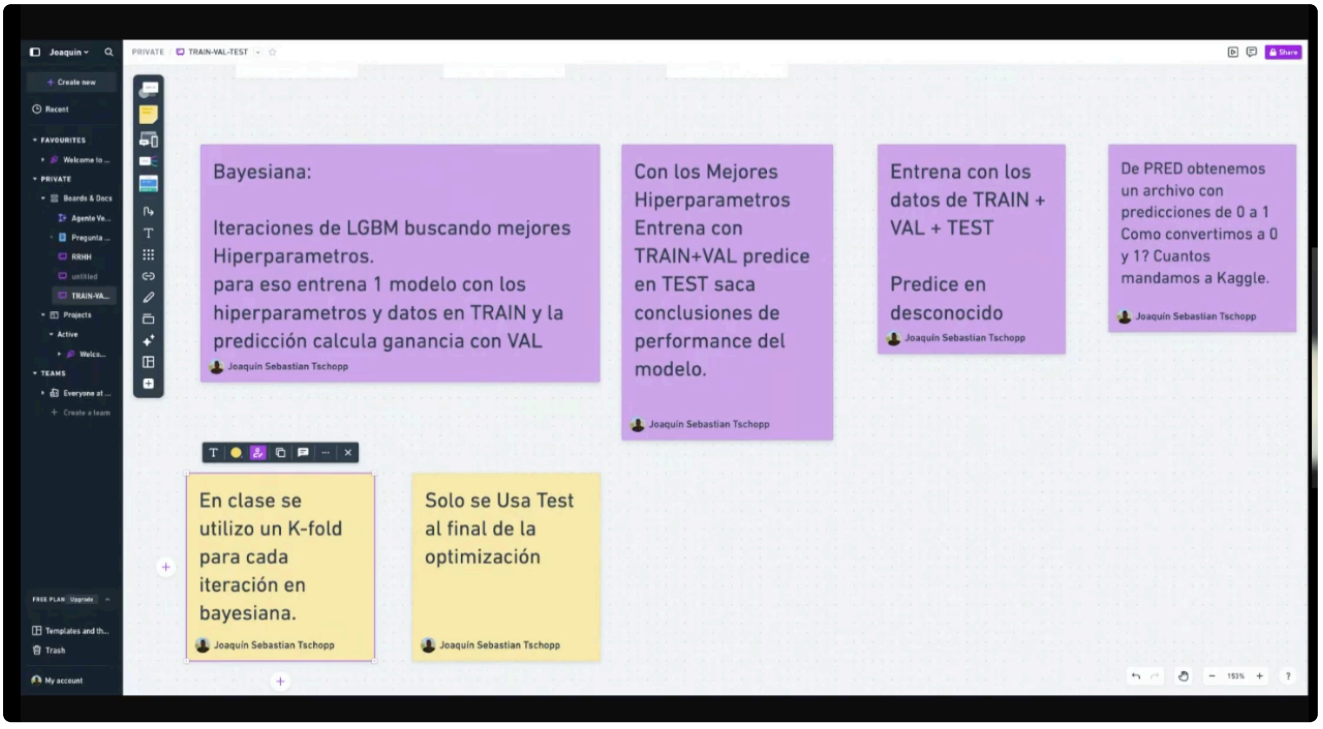

Este es un esquema posible (en violeta). Asigno meses de Train, Val, Test y Desconocido La Bayesiana se hace con Train + Val. Train para entrenarlo, Val para ver como da. Se optimiza contra las predicciones efectuadas en Val. Una vez elegidos los mejores HP, se hace una comprobación final con Test para evaluar la performance de los HP obtenidos. Finalmente se entrena usando Train + Val + Test y se predice en Desconocido para reportar a Kaggle.

Otro modo posible (en amarillo), es lo que se usa en los notebooks de la clase.
Se toma Train y se hace un K-fold. Se optimizan HP usando K-1 folds, y se optimizan contra el fold que quedó para validar. Se hace un promedio tomando los K-folds de K

maneras. Se cambian los HP y se vuelve a repetir el proceso. Esto se hace hasta encontrar el juego óptimo de HPs. Luego se hace una valoración de la performance de estos HP usando Test.
Finalmente se entrena en Train + Test y se predice en Desconocido. Es decir, si uso K-fold, no uso Validación, ésta está incluida en el K-Fold (Train).
El K-fold es más robusto porque son K entrenamientos vs 1 en cada juego de HPs.
Lo que hay que tener en cuenta es que en el entrenamiento final estoy usando datos que no fueron usados en la optimización de HPs.

Llamemos al esquema que no usa K-fold sino Validación, Val y al de K-fold lo llamamos K-fold.

Entonces, el esquema Val usa:
bo_train = [202101, 202102]
bo_validation = [202103]
bo_test = [202104]
final_train = [202101, 202102, 202103, 202104]
final_pred = [202106]

Antes de pensar esto, fijate que yo tengo los baja+1 y baja+2 de todos los meses hasta 202104 (son los que ya no están en 202106)
Pensemos que no es óptimo hacer una optimización bayesiana sobre bo_train y después el entrenamiento en la prediccion buena (la que se va a usar para Kaggle) hacerlo sobre final_train que es un dataset diferente.
Joaquín dice que en lugar de hacer esto convendría hacer una cross validation (K-fold) con los meses 202101 a 04.
Entonces hago la BO sobre el mismo dataset donde después voy a predecir. No hace falta, en ese caso, hacer Validation ni Test, éstos están incluidos en el K-fold.